

目录

第一部分 贝叶斯公式 Bayes' theorem :

$$P(A_k|B) = \frac{P(A_k) \cdot P(B|A_k)}{\sum_{i=1}^n [P(A_i) \cdot P(B|A_i)]} = \frac{P(A_k B)}{P(B)}$$

2

- 1 先验概率 (从经验来推后果) & 后验概率(更新迭代经验)2
- 2 贝叶斯公式: 从“果”, 来推是“某因”的可能性大小2

文件名

第一部分 贝叶斯公式 Bayes' theorem :

$$P(A_k|B) = \frac{P(A_k) \cdot P(B|A_k)}{\sum_{i=1}^n [P(A_i) \cdot P(B|A_i)]} = \frac{P(A_k B)}{P(B)}$$

1 先验概率 (从经验来推后果) & 后验概率(更新迭代经验)

先验概率：是指根据以往经验和分析得到的概率，它往往作为“由因求果”问题中的“因”出现.	“先验概率”的计算比较简单，没有使用“贝叶斯公式”.
后验概率: 是基于新的信息，修正原来的“先验概率”后，所获得的更接近实际情况的概率估计.	“后验概率”的计算，要使用“贝叶斯公式”.

2 贝叶斯公式：从“果”，来推是“某因”的可能性大小

根据新信息，不断调整对一个随机事件发生概率的判断，这就是“贝叶斯推理”。即反复迭代，不断逼近真相 (即人工智能的原理).

通常，“事件A, 在事件B(发生)的条件下的概率”，与“事件B, 在事件A的条件下的概率”，是不一样的. 然而，这两者是有确定的关系，“贝叶斯法则”就是对这种关系的陈述。

推导1：

“条件概率”的公式是 $P(B|A) = \frac{P(AB)}{P(A)}$ ①

可进一步变换为： $P(AB) = P(A) \cdot P(B|A)$

改变 A 和 B 的顺序，就得到： $\underbrace{P(BA)}_{\substack{P(AB) \\ \text{是 } AB \text{ 同时发生的概率,} \\ \text{其实就} = P(BA)}} = P(B) \cdot P(A|B)$ ②

把公式 ②代入公式 ①，就得到： $P(B|A) = \frac{\underbrace{P(AB)}_{= P(BA) = P(B) \cdot P(A|B)}}{P(A)} = \frac{P(B) \cdot P(A|B)}{P(A)}$

即： $P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)}$$

③ ← 这个就是 “贝叶斯公式”

上面“贝叶斯公式”的意思就是说：“在现象B出现的条件下，事件A发生的概率” (即 P(A—B)), 就等于“事件A发生的概率 (即 P(A))”, 乘以 “事件A发生条件下，事件B出现的概率” (即 P(B—A)), 再除以“事件B出现的概率” (即 P(B)).

推导2：

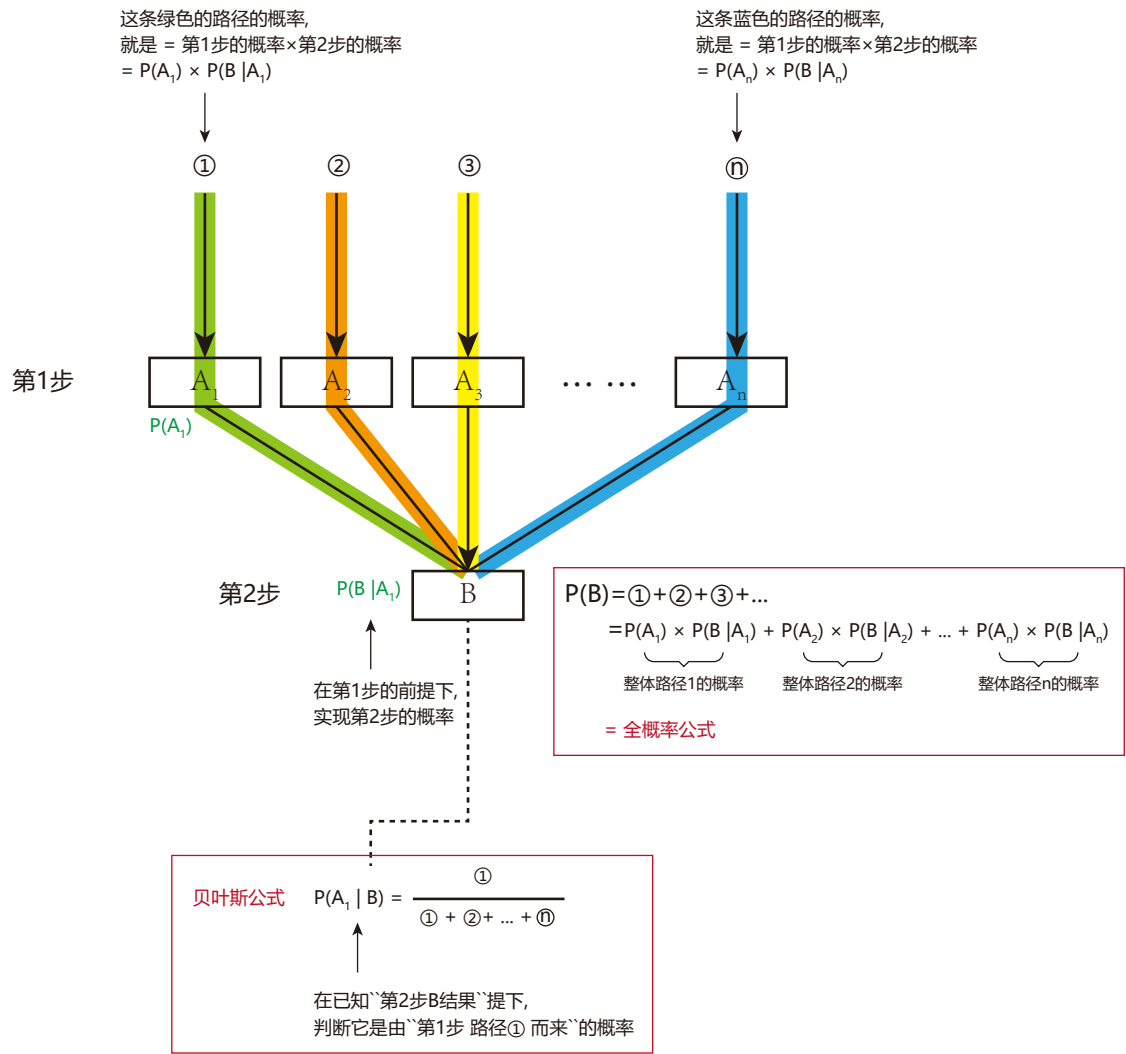
有条件概率: $P(B|A_i) = \frac{P(A_i \cap B)}{P(A_i)}$ ①

即: $P(A_i B) = P(A_i) \cdot P(B|A_i)$ ②

然后, 对 ①式, 我们把 A_i 和 B 倒一倒, 让 B 作为条件, 即有:

$$P(A_i|B) = \frac{\overbrace{P(A_i B)}^{\text{分子即式②的内容}}}{\underbrace{P(B)}_{\text{分母即“全概率公式”}}} \leftarrow \text{分母的 } P(B) = \sum_{i=1}^n [P(A_i) \cdot P(B|A_i)]$$
$$= \underbrace{P(A) \cdot P(B|A)} + \underbrace{P(\bar{A}) \cdot P(B|\bar{A})}$$
$$= \frac{\overbrace{P(A_i) \cdot P(B|A_i)}^{i \text{ 可取 } 1 \text{ 到 } n \text{ 中的任何索引值, 即任何一条路径}}}{\sum_{i=1}^n [P(A_i) \cdot P(B|A_i)]} = \frac{\overbrace{P(A_i) \cdot P(B|A_i)}^{\leftarrow \text{条件概率}}}{\overbrace{\sum_{i=1}^n [P(A_i) \cdot P(B|A_i)]}^{\leftarrow \text{全概率公式}}} \quad \text{③} \leftarrow \text{这个就是“贝叶斯公式”}$$

推导3:



→ 到第一步的, 其实就是“贝叶斯公式”. 即已知第二步的结果 B , 我们来倒推推测它到底是从哪条路径走过来的 (即在第一步中是从哪个路口过来的). 比如, 如果从第 A_1 节点过来, 那么其概率就是: $P(A_1|B) = \frac{\text{路径1的概率}}{\text{路径1的概率} + \text{路径2的概率} + \dots + \text{路径n的概率}}$

即:

$$P(A_i|B) = \frac{P(A_i) \cdot P(B|A_i)}{\sum_{j=1}^n [P(A_j) \cdot P(B|A_j)]} = \frac{\overbrace{P(A_i) \cdot P(B|A_i)}^{\text{第 } i \text{ 条路径的概率}}}{\underbrace{P(A_1) \cdot P(B|A_1) + \dots + P(A_n) \cdot P(B|A_n)}_{\text{分母上是把所有路径概率, 都加起来} = P(B) = \text{全概率公式}}}$$

→ 到第二步的, 其实就是“全概率公式”, 即:

$$P(B) = \underbrace{P(A_1) \cdot P(B|A_1)}_{\text{整条路径1的概率}} + \underbrace{P(A_2) \cdot P(B|A_2)}_{\text{整条路径2的概率}} + \dots + \underbrace{P(A_n) \cdot P(B|A_n)}_{\text{整条路径n的概率}}$$

宋浩的上课 :

有事件 A_1, A_2, \dots, A_n 组成“完备事件组” (它们作为“原因事件”), $P(A_i) > 0$

有一个事件B (作为“结果事件”), $P(B) > 0$

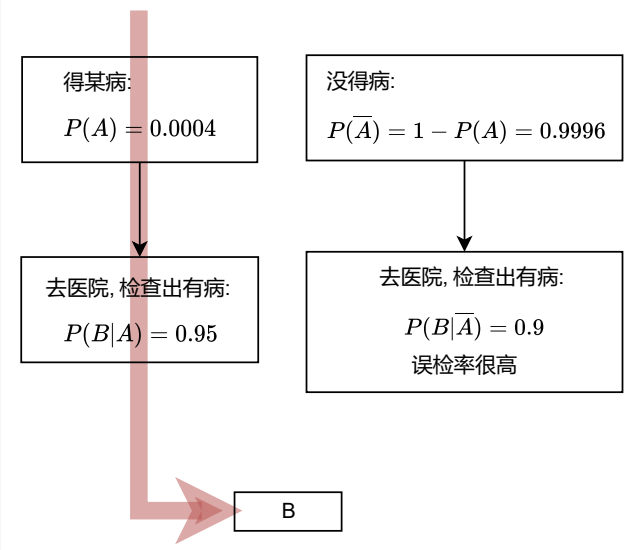
则: 从B结果, 来倒推推断“它是由第 A_k 个原因造成的”的可能性占多大的概率, 就由这个公式(贝叶斯公式)给出:

$$\begin{aligned} P(\text{原因}A_k \mid \text{结果}B) &= \frac{P(\text{原因}A_k \cap \text{结果}B)}{P(\text{结果}B)} \\ &= \frac{P(\text{原因}A_k) \cdot P(\text{结果}B \mid \text{原因}A_k)}{\sum_{i=1}^n [P(\text{原因}A_i) \cdot P(\text{结果}B \mid \text{原因}A_i)]} \\ &= \frac{A_k \text{ 这个人, 他的责任量}}{\text{所有相关的人(所有的}A\text{), 责任加起来的总和量}} \end{aligned}$$

例

得某病 ← 事件A

医院检查出有病 ← 事件B



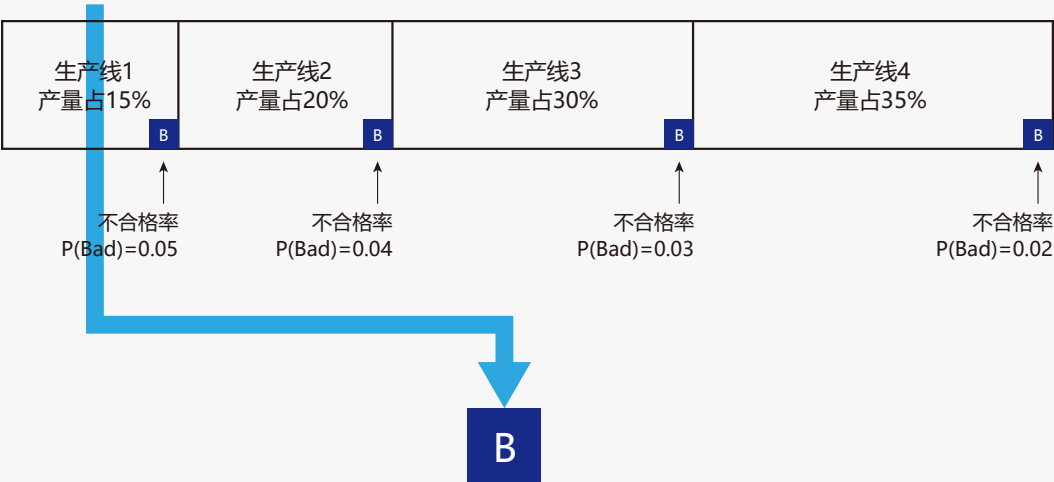
在某人检测出有病(B)的前提下, 问“其是真实患病(A)”的概率是多少? (即走的是上面红色路径的概率). 即求: $P(A|B) = ?$

$$\begin{aligned} P(A|B) &= \frac{P(AB)}{P(B)} \\ &= \text{或用贝叶斯公式} \frac{P(A_k) \cdot P(B|A_k)}{\sum_{i=1}^n [P(A_i) \cdot P(B|A_i)]} \\ &= \frac{P(A) \cdot P(B|A)}{P(A) \cdot P(B|A) + P(\bar{A}) \cdot P(B|\bar{A})} \\ &= \frac{0.0004 \cdot 0.95}{(0.0004 \cdot 0.95) + (0.9996 \cdot 0.9)} = 0.000422213 \end{aligned}$$

所以, 你可以看出:

- 全概率公式, 是从“原因”来推“结果的可能性是多少”.
- 贝叶斯公式, 是从“结果”来倒推其“是从哪一种原因得来的”的可能性. 即 $P(\text{原因}_i | \text{结果})$

例



一个工厂, 有4条生产线, 情况如下:

	生产线1	生产线2	生产线3	生产线4
产量	15%	20%	30%	35%
不合格率	0.05	0.04	0.03	0.02

我们设:

- A_1 : 代表生产线1的产品
- A_2 : 代表生产线2的产品
- A_3 : 代表生产线3的产品
- A_4 : 代表生产线4的产品
- B (bad): 代表不合格品.

则, 这个工厂的总的不合格率:


即全概率公式

$$P(B) = \overbrace{P(A_1) \cdot P(B|A_1) + \dots + P(A_4) \cdot P(B|A_4)}^{\text{第1条生产线的产量占比, 乘以第1条生产线的不合格率}}$$
$$= (0.15 \cdot 0.05) + (0.2 \cdot 0.04) + (0.3 \cdot 0.03) + (0.35 \cdot 0.02) = 0.0315$$

全概率公式的图解

设有样本空间 S 及其中某一事件为 B , 按如下方式构造一完备事件组 $\{A_i\} (i=1, 2, \dots, 10)$, 注意到事件 A_i 发生的条件下事件 B 发生的概率为 $P(BA_i)=P(A_i)P(B|A_i)$, 则

$$P(B)=P(A_1)P(B|A_1)+\dots+P(A_{10})P(B|A_{10})$$



现在问: 在发生了B结果的前提下, 它是由 A_1 原因(路径)引起的可能性, 是多少? ← 这就是要用“贝叶斯公式”了. 从“结果”, 来问“某原因”导致的可能性是多少.

$$P(A_1|B) = \frac{P(A_1B)}{P(B)} = \frac{\overbrace{P(A_1)}^{A_1\text{生产线产量占}0.15} \cdot \overbrace{P(B|A_1)}^{A_1\text{生产线的不合格率}=0.05}}{\underbrace{P(B)}_{\text{这个工厂总的不合格率}=0.0315}} = \frac{0.15 \cdot 0.05}{0.0315} = 0.238095$$

同理, 其他原因(其他生产线带来的次品)的可能性是:

$$P(A_2|B) = \frac{P(A_2B)}{P(B)} = \frac{P(A_2) \cdot P(B|A_2)}{P(B)} = \frac{0.2 \cdot 0.04}{0.0315} = 0.253968$$

$$P(A_3|B) = \frac{P(A_3B)}{P(B)} = \frac{P(A_3) \cdot P(B|A_3)}{P(B)} = \frac{0.3 \cdot 0.03}{0.0315} = 0.285714$$

$$P(A_4|B) = \frac{P(A_4B)}{P(B)} = \frac{P(A_4) \cdot P(B|A_4)}{P(B)} = \frac{0.35 \cdot 0.02}{0.0315} = 0.222222$$

所以, 是第3条生产线造成的原因的可能性最大, 因为其概率值最高.

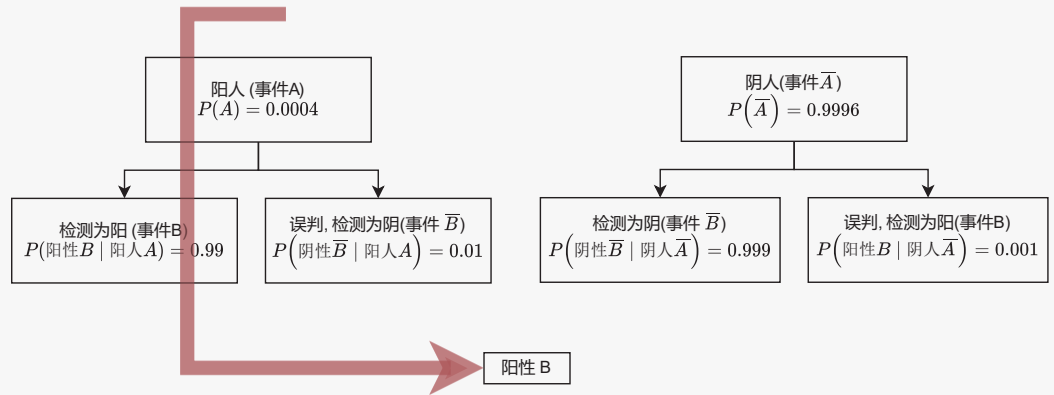
例

某病, 发病率是 0.0004. 有种检测方法, 但存在误诊情况.

我们先设定事件:

- 事件A: 表示某人真有病, 即阳性
- 事件 \bar{A} : 表示某人无病, 阴性
- 事件B: 表示检测认为该人阳性.

该检测方法, 准确度如下:




问: 一个人被检测为“阳”, 那么他真的是“得病”的概率是? 即问: $P(\text{阳人}A | \text{阳性}B = ?)$

$$P(\text{前后}) = P(\text{前}) \cdot P(\text{后} | \text{前})$$
$$P(A|B) = \frac{\overbrace{P(AB)}^{\text{任何一个人被检测为阳的概率}}}{\underbrace{P(B)}} = \frac{P(A) \cdot P(B|A)}{P(B)}$$

$$= \frac{\overbrace{P(A)}^{=0.0004} \cdot \overbrace{P(B|A)}^{=0.99}}{\underbrace{P(A) \cdot P(B|A)}_{\text{无误诊, 将患者}(A)\text{确认为阳性}(B)} + \underbrace{P(\bar{A}) \cdot P(B|\bar{A})}_{\text{有误诊, 将阴人}(\bar{A})\text{误诊为阳性}}}$$

$$= \frac{0.0004 \cdot 0.99}{0.0004 \cdot 0.99 + 0.9996 \cdot 0.001} = 0.283749$$



概率告诉我们: 要相信长期中的期望. $0.99^{365} = 0.025518$, 而 $1.01^{365} = 37.7834$.
篮球领域有一句名言——“训练时, 用正确姿势投丢的球, 比用错误姿势投进的球, 更有价值.”
站在当下, 未来任何事都只是一个概率. 所谓坚持, 所谓努力, 其实就是寻找一个大概率成功的方向, 然后相信系统, 相信长期主义. 当然, 你得坚持活着. 等到长期的到来.

但行为经济学家发现, 人们在决策过程中, 往往并不遵循“贝叶斯规律”, 而是给予最近发生的事件和最新的经验, 以更多的权重值, 更看重近期的事件。面对复杂问题, 人们往往会走捷径, 依据可能性, 而非概率来做决策. 这种对经典模型的系统性偏离, 称为“偏差”. 因此, 投资者在决策判断时, 并非绝对理性.
但长期以来, 由于缺乏有力的“能结合人类决策中的理性和感性因素”的替代工具, 经济学家不得不在分析中坚持“贝叶斯法则”.